
UNIVERSIDAD NACIONAL AUTÓNOMA DE HONDURAS

Campus Comayagua (UNAH-CURC)

Asignatura: Inteligencia Artificial



AgroDetect

Sistema Inteligente para la De- tección de Enfermedades y Pla- gas Foliares en el Cultivo de Café

*Un anteproyecto de Inteligencia Artificial apli-
cado a la caficultura de Comayagua, Honduras*

Anteproyecto

Integrantes

Jeimy Jazmín Palma Santos 20221900269

Ángeles Izamar Euceda Herrera 20221930061

Kilver Said Nolasco Parada 20221930129

Docente: Asalia Alejandra Zavala

Fecha: 14 de julio de 2026

Índice

1	Introducción	2
1.1	Descripción general del problema	2
1.2	Justificación del uso de Inteligencia Artificial	2
2	Planteamiento del problema	3
2.1	Situación actual	3
2.2	Problema que se pretende resolver	4
3	Objetivos	4
4	Metodología propuesta	5
4.1	Descripción del proceso para desarrollar la solución	5
4.2	Tipo de datos que se utilizarán	6
4.3	Algoritmos o técnicas de Inteligencia Artificial a implementar	8
4.4	Sistema de recomendaciones mediante API	8
4.5	Herramientas y tecnologías a utilizar	10
5	Beneficiarios del proyecto	10
5.1	Usuarios finales	10
5.2	Beneficios esperados	10
6	Despliegue de la solución	11
6.1	Funcionamiento de la aplicación	11
6.2	Plataforma de despliegue propuesta	11
7	Mantenimiento de la solución	12
7.1	Operación continua	12
7.2	Estrategia de actualización del modelo	12
7.3	Mantenimiento preventivo y correctivo	12
7.4	Respaldo de la información y mejoras futuras	12
8	Cronograma de actividades	13
9	Referencias bibliográficas	14

1 Introducción

1.1 Descripción general del problema

El café es uno de los pilares de la economía hondureña: el país se ubica entre los principales exportadores de Centroamérica y Latinoamérica, y este rubro genera ingresos directos e indirectos para cientos de miles de familias, incluidas numerosas comunidades productoras del departamento de Comayagua. Sin embargo, la caficultura hondureña enfrenta una amenaza recurrente y creciente: las enfermedades foliares, en particular la **roya del café** (*Hemileia vastatrix*), que provoca la caída prematura de las hojas, debilita la planta y, en casos severos de defoliación extrema, puede causar la muerte del cafeto. A esta se suman otras afecciones comunes como la *cercospora* y la *phoma*, así como plagas que también dañan visiblemente el follaje, como la *araña roja* (*red spider mite*) y el *minador de la hoja* (*leaf miner*); todas ellas reducen el rendimiento y la calidad del grano.

De acuerdo con reportes recientes del Instituto Hondureño del Café (IHCAFE), la incidencia promedio nacional de la roya continúa en aumento, y una proporción considerable de las fincas muestreadas presenta niveles de infección altos, lo que representa un riesgo constante para la producción nacional. Históricamente, la crisis de roya de los ciclos 2012-2013 provocó una caída superior al 20 % en el volumen exportado de café hondureño, con fuertes pérdidas económicas y de empleo en las zonas rurales cafetaleras.

En la actualidad, el diagnóstico de estas enfermedades en el campo depende principalmente de la inspección visual realizada por el productor o, en el mejor de los casos, por un técnico agrónomo. Este método es lento y subjetivo, y depende en gran medida de la experiencia de quien observa la hoja, especialmente en fincas pequeñas y medianas donde el acceso a asistencia técnica especializada es limitado, como ocurre en varias comunidades cafetaleras de la zona sur y central del departamento de Comayagua.

1.2 Justificación del uso de Inteligencia Artificial

La Inteligencia Artificial, particularmente las técnicas de **visión artificial** y **aprendizaje profundo** (*Deep Learning*), ha demostrado ser altamente efectiva para la identificación automática de enfermedades y plagas en hojas de cultivos a partir de imágenes. Investigaciones recientes reportan modelos de redes neuronales convolucionales (CNN) capaces de clasificar enfermedades foliares del café con niveles de exactitud superiores al 90 %, utilizando arquitecturas de transferencia de aprendizaje como ResNet, VGG y MobileNet (el equipo completará las referencias específicas de estos estudios en la sección de Referencias bibliográficas).

El uso de IA para este problema se justifica por las siguientes razones:

- ❑ Permite un **diagnóstico objetivo y consistente**, reduciendo la dependencia exclusiva del juicio visual del productor.
- ❑ Es **escalable**: una vez entrenado, el modelo puede analizar miles de imágenes sin fatiga ni variabilidad de criterio.
- ❑ Puede desplegarse en una **aplicación accesible desde un teléfono inteligente**, herramienta cada vez más presente entre los productores de café de Honduras, incluso en zonas rurales.
- ❑ Contribuye a la **reducción de pérdidas económicas** al permitir intervenciones fitosanitarias más oportunas y focalizadas.
- ❑ Se alinea con los esfuerzos institucionales de IHCAFE en materia de monitoreo permanente de plagas y enfermedades, aportando una herramienta complementaria de bajo costo.

2 Planteamiento del problema

2.1 Situación actual

En Comayagua, al igual que en gran parte de las zonas cafetaleras de Honduras, la mayoría de los productores son pequeños y medianos caficultores que gestionan sus fincas de manera artesanal, con acceso limitado y esporádico a técnicos especializados del IHCAFE u otras instituciones de extensión agrícola. El diagnóstico de enfermedades y plagas foliares se realiza casi exclusivamente por observación directa, un proceso que:

- ❑ Depende de la experiencia y capacitación previa del productor, lo cual genera diagnósticos inconsistentes.
- ❑ No permite cuantificar objetivamente el grado de severidad de la infección.
- ❑ Retrasa la toma de decisiones sobre el manejo fitosanitario (aplicación de fungicidas, poda, renovación de plantas), lo que agrava el impacto de la enfermedad.
- ❑ Se dificulta aún más en fincas de difícil acceso geográfico, comunes en la topografía montañosa de Comayagua.

2.2 Problema que se pretende resolver

Problema central: Los pequeños y medianos productores de café de Comayagua carecen de una herramienta accesible, rápida y confiable que les permita identificar las principales enfermedades y plagas foliares del cafeto (roya, cercospora, phoma, araña roja y minador de la hoja), lo que provoca diagnósticos tardíos, aumento en la severidad de las infecciones e infestaciones, y pérdidas económicas evitables.

Este proyecto busca reducir esa brecha mediante el desarrollo de un sistema basado en visión artificial que, a partir de una fotografía tomada con un teléfono móvil, sea capaz de clasificar el estado de salud de una hoja de café y sugerir la enfermedad o plaga presente, funcionando como una primera línea de apoyo al diagnóstico agronómico.

3 Objetivos

Objetivo general

Desarrollar un sistema basado en Inteligencia Artificial, utilizando técnicas de visión artificial y aprendizaje profundo, para la detección y clasificación de enfermedades y plagas foliares en el cultivo de café, como herramienta de apoyo al diagnóstico fitosanitario de los productores de la región de Comayagua, Honduras.

Objetivos específicos

- ❑ Recopilar y curar un conjunto de datos (*dataset*) a partir de repositorios públicos de imágenes de hojas de café sanas y afectadas por las cinco clases priorizadas para este proyecto: las enfermedades roya, cercospora y phoma, y las plagas araña roja y minador de la hoja.
- ❑ Diseñar y entrenar un modelo de clasificación de imágenes basado en redes neuronales convolucionales (CNN) mediante técnicas de *transfer learning*.
- ❑ Evaluar el desempeño del modelo utilizando métricas estándar (exactitud, precisión, sensibilidad y F1-score) sobre un conjunto de prueba independiente.
- ❑ Desarrollar una interfaz web accesible e intuitiva que permita a los productores subir o capturar una fotografía de una hoja de café y recibir un diagnóstico automatizado.
- ❑ Integrar un **módulo de recomendaciones basado en un modelo de lenguaje (LLM)**, consumido mediante una API key desde la propia aplicación, que a partir

del diagnóstico generado por el modelo de visión entregue al productor sugerencias prácticas de manejo agronómico correspondientes a la enfermedad o plaga detectada.

- ❑ Desplegar la solución en una plataforma en la nube de acceso gratuito para su validación con productores de la zona.
- ❑ Definir una estrategia de mantenimiento, actualización y mejora continua del sistema a partir de la retroalimentación de los usuarios finales.

4 Metodología propuesta

4.1 Descripción del proceso para desarrollar la solución

El desarrollo del proyecto seguirá una metodología iterativa inspirada en el ciclo **CRISP-DM** (*Cross Industry Standard Process for Data Mining*), adaptada al desarrollo de soluciones de visión artificial. Las fases propuestas son:

1. **Comprensión del problema y del contexto agronómico:** revisión de literatura técnica y consulta de material del IHCAFE sobre síntomas y ciclos de las principales enfermedades y plagas foliares del café.
2. **Recolección y curaduría de datos:** búsqueda, descarga y organización de imágenes provenientes de repositorios públicos especializados en enfermedades y plagas foliares del café (ver sección 4.2), seleccionando y filtrando las imágenes correspondientes a las clases priorizadas por el equipo.
3. **Preprocesamiento de datos:** limpieza, normalización, redimensionamiento, y aumento de datos (*data augmentation*: rotaciones, volteos, ajustes de brillo/contraste) para mejorar la robustez del modelo ante condiciones reales de campo.
4. **Modelado:** entrenamiento de modelos de redes neuronales convolucionales mediante *transfer learning*, comparando el desempeño de distintas arquitecturas preentrenadas.
5. **Evaluación:** validación cruzada y análisis de métricas de desempeño (matriz de confusión, exactitud, precisión, sensibilidad, F1-score).
6. **Implementación:** construcción de una aplicación web que integre el modelo entrenado y permita su uso por productores no técnicos.
7. **Despliegue y validación:** publicación en una plataforma en la nube y pruebas piloto con productores de café de Comayagua, para recoger retroalimentación sobre la utilidad y precisión percibida del sistema.

4.2 Tipo de datos que se utilizarán

El proyecto no contempla la captura de fotografías propias en campo; en su lugar, se trabajará exclusivamente con **imágenes digitales de hojas de café provenientes de repositorios públicos (*datasets*) ya existentes**, disponibles en plataformas académicas de acceso abierto. Este enfoque permite partir de conjuntos de datos ya etiquetados y validados por especialistas, reduciendo el tiempo de recolección y enfocando el esfuerzo del equipo en el preprocesamiento, el modelado y el desarrollo de la aplicación.

Enfermedades y plagas priorizadas

De acuerdo con su relevancia e incidencia en la caficultura hondureña, el equipo priorizó **cinco clases** como núcleo del proyecto: tres corresponden a **enfermedades** foliares y dos a **plagas** que también afectan visiblemente la hoja del cafeto. Estas cinco clases (más la clase *hoja sana*) serán la base de todo el desarrollo, entrenamiento y evaluación del modelo a lo largo de este informe.

Clase	Tipo	Alcance dentro del proyecto
Roya (<i>Hemileia vastatrix</i>)	Enfermedad	Clasificación de la enfermedad.
Cercospora	Enfermedad	Clasificación de presencia/ausencia de la enfermedad en la hoja.
Phoma	Enfermedad	Clasificación de presencia/ausencia de la enfermedad en la hoja.
Araña roja (<i>red spider mite</i>)	Plaga	Clasificación de presencia/ausencia de la plaga en la hoja.
Minador de la hoja (<i>leaf miner</i>)	Plaga	Clasificación de presencia/ausencia de la plaga en la hoja.

Tabla 1: Enfermedades y plagas priorizadas por el equipo, seleccionadas por ser las más usuales en la caficultura de Honduras.

Repositorios de datos a utilizar

Roya (*Hemileia vastatrix*), enfermedad:

- ❑ **RoCoLe – A robusta coffee leaf images dataset** (Mendeley Data): imágenes de hojas de café robusta con anotaciones de estado (sana/enferma).
<https://data.mendeley.com/datasets/c5yvn32dzg/2>
- ❑ **CLR-Dataset** (GitHub): imágenes de roya del café etiquetadas por severidad, generadas por un sistema de recolección de datos ciber-físico.
<https://github.com/dvelaren/clr-dataset/tree/master/data/0>

Cercospora, enfermedad:

- ❑ Coffee Leaf Disease (Roboflow Universe), clase *brown_eye_spot* (bifurcación/*fork*):
https://universe.roboflow.com/dame-23kub/coffee-leaf-disease-kc1ca/browse/fork?queryText=class%3A%22brown_eye_spot%22&pageSize=50&startingIndex=0&browseQuery=true
- ❑ Coffee Leaf Disease (Roboflow Universe), conjunto completo:
<https://universe.roboflow.com/dame-23kub/coffee-leaf-disease-kc1ca/browse?queryText=&pageSize=50&startingIndex=0&browseQuery=true>
- ❑ Barakobama Coffee Leaf Disease (Roboflow Universe):
<https://universe.roboflow.com/barakobama/barakobama-coffee-leaf-disease/browse?queryText=&pageSize=50&startingIndex=0&browseQuery=true>
- ❑ Ethiopian Coffee Leaf Disease (Kaggle):
<https://www.kaggle.com/datasets/biniyamyoseph/ethiopian-coffee-leaf-disease?select=ethiopian+cofee+leaf+dataset>
- ❑ Coffee Dataset (Roboflow Universe), clase *cercospora*:
<https://universe.roboflow.com/letang-dataset/coffee-dataset-gh98d/browse?queryText=class%3Acercospora&pageSize=50&startingIndex=0&browseQuery=true>

Phoma, enfermedad:

- ❑ Ethiopian Coffee Leaf Disease (Kaggle), clase :
<https://www.kaggle.com/datasets/biniyamyoseph/ethiopian-coffee-leaf-diseasev>
- ❑ JMuBEN Coffee Dataset (Kaggle):
<https://www.kaggle.com/datasets/noamaanabdulazeem/jmuben-coffee-dataset/data>
- ❑ Coffee Leaf Diseases(Kaggle) <https://www.kaggle.com/datasets/izzaiqbal/capstone-project>

Minador de la hoja (*leaf miner*), plaga:

- ❑ Ethiopian Coffee Leaf Disease (Kaggle), clase :
<https://www.kaggle.com/datasets/biniyamyoseph/ethiopian-coffee-leaf-diseasev>
- ❑ JMuBEN Coffee Dataset (Kaggle):
<https://www.kaggle.com/datasets/noamaanabdulazeem/jmuben-coffee-dataset/data>
- ❑ Coffee Leaf Diseases(Kaggle) <https://www.kaggle.com/datasets/izzaiqbal/capstone-project>

Araña roja (*red spider mite*) , plaga:

- ❑ Coffee Leaf Disease (Roboflow Universe), clase *Red Spider Mite*:
`https://universe.roboflow.com/yolonasv1/coffee-leaf-disease-o9dbv/browse?queryText=class%3A%22Red+Spider+Mite%22&pageSize=50&startIndex=0&browseQuery=true`
- ❑ Red Spider Mite (Roboflow Universe):
`https://universe.roboflow.com/lance-eugene/red-spider-mite/browse?queryText=class%3A%22Roboflow+is+an+end-to-end+computer+vision+platform+that+helps+you%22&pageSize=50&startIndex=600&browseQuery=true`
- ❑ RoCoLe – A Robusta Coffee Leaf Images Dataset (Kaggle, espejo de RoCoLe) `https://www.kaggle.com/datasets/nirmalsankalana/rocole-a-robusta-coffee-leaf-images-dataset?select=coffee\_\_healthy`
- ❑ ROCC (Roboflow Universe), clase *red_spider_mite*:
`https://universe.roboflow.com/coffee-leaf-detection/rocc/browse?queryText=class%3A%22red\_spider\_mite%22&pageSize=50&startIndex=100&browseQuery=true`

Nota del equipo: para la clase de *araña roja* se reutilizan los mismos tres primeros repositorios listados en Cercospora, ya que estos también contienen imágenes etiquetadas para dicha clase. El equipo continúa evaluando la incorporación de un repositorio adicional específico para esta categoría.

4.3 Algoritmos o técnicas de Inteligencia Artificial a implementar

- ❑ **Visión artificial (Computer Vision)** para el procesamiento y análisis de las imágenes de las hojas.
- ❑ **Aprendizaje profundo (Deep Learning)** mediante **Redes Neuronales Convolucionales (CNN)**, arquitectura de referencia para tareas de clasificación de imágenes.
- ❑ **Transfer Learning** sobre modelos preentrenados como **MobileNetV2**, **ResNet50** o **EfficientNet**, que permiten obtener buen desempeño incluso con conjuntos de datos de tamaño moderado, reduciendo el tiempo y el costo computacional de entrenamiento.
- ❑ Técnicas de **aumento de datos** (*data augmentation*) para mitigar el sobreajuste (*overfitting*) dado el tamaño limitado del dataset inicial.

4.4 Sistema de recomendaciones mediante API

Además de la clasificación de la enfermedad, el sistema incorporará un **módulo de recomendaciones** basado en un modelo de lenguaje (LLM), integrado directamente en la aplicación de **Streamlit** mediante una **API key**. Tras evaluar distintas alternativas, el equipo optó

por **Groq** como proveedor de inferencia, debido a que ofrece un nivel gratuito con límites de uso adecuados para un proyecto académico y tiempos de respuesta muy bajos (baja latencia), gracias a su infraestructura especializada en inferencia de LLMs. El funcionamiento propuesto es el siguiente:

1. El modelo de visión artificial clasifica la imagen de la hoja y determina la enfermedad o plaga presente.
2. La propia aplicación de **Streamlit** construye un *prompt* con la clase detectada y realiza, mediante la librería oficial de Groq para Python, una petición directa a la **API de Groq**, usando una API key almacenada de forma segura como variable de entorno o en los *secrets* de la plataforma de despliegue.
3. El modelo de lenguaje alojado en Groq (por ejemplo, una variante de **Llama** disponible en su catálogo) genera, a partir de un *prompt* cuidadosamente diseñado por el equipo, recomendaciones prácticas de manejo agronómico para la clase detectada (por ejemplo: poda sanitaria, control cultural, momento oportuno de aplicación de fungicida o pesticida, o remisión a un técnico del IHCAFE).
4. La aplicación recibe la respuesta y la muestra al productor junto con el resultado del diagnóstico, en la misma interfaz.

Esta arquitectura, al no requerir un servicio de backend independiente (como una API propia con FastAPI), simplifica considerablemente el despliegue y el mantenimiento del proyecto: toda la lógica de la aplicación reside en un único servicio de Streamlit, que se comunica directamente con la API externa de Groq. Como medida de respaldo, el equipo documentará el diseño del *prompt* y las reglas de negocio asociadas a cada clase, de manera que, si en una fase posterior se requiere mayor control o el consumo desde otras interfaces (por ejemplo, una futura aplicación móvil), esta lógica pueda migrarse a una API propia sin mayor dificultad.

4.5 Herramientas y tecnologías a utilizar

Categoría	Herramienta / Tecnología
Lenguaje de programación	Python
Frameworks de Deep Learning	TensorFlow / Keras (alternativa: PyTorch)
Procesamiento de imágenes	OpenCV, Pillow
Entrenamiento y experimentación	Google Colab (uso de GPU gratuita)
Etiquetado y gestión de datasets	Roboflow
Desarrollo de interfaz de usuario	Streamlit
Recomendaciones mediante LLM	API de Groq (API key), consumida directamente desde Streamlit
Control de versiones	Git y GitHub
Documentación y análisis	Jupyter Notebook, pandas, matplotlib

Tabla 2: Herramientas y tecnologías propuestas para el desarrollo del proyecto.

5 Beneficiarios del proyecto

5.1 Usuarios finales

- ❑ **Pequeños y medianos productores de café** del departamento de Comayagua, principalmente aquellos con acceso limitado a asistencia técnica especializada.
- ❑ **Técnicos agrónomos y extensionistas** del IHCAFE y de cooperativas cafetaleras locales, quienes podrán utilizar la herramienta como apoyo en sus visitas de campo.
- ❑ **Cooperativas y asociaciones de caficultores** de la región, interesadas en mejorar la productividad y calidad de sus asociados.
- ❑ **Estudiantes y docentes** de carreras agronómicas o afines que deseen utilizar la herramienta con fines educativos.

5.2 Beneficios esperados

- ❑ **Diagnóstico más rápido y accesible**, sin necesidad de esperar la visita de un técnico especializado.
- ❑ **Identificación oportuna** de enfermedades y plagas, lo que permite tomar decisiones de manejo fitosanitario más adecuadas y reducir pérdidas de cosecha.
- ❑ **Reducción de costos** asociados al uso indiscriminado de fungicidas y pesticidas, al facilitar un manejo más focalizado.

- ❑ **Democratización del conocimiento agronómico**, poniendo a disposición de cualquier productor con un teléfono inteligente una herramienta de diagnóstico preliminar.
- ❑ **Generación de datos útiles** para futuras investigaciones sobre la incidencia de enfermedades y plagas del café en la región.

6 Despliegue de la solución

6.1 Funcionamiento de la aplicación

La solución se implementará como una **aplicación web ligera** desarrollada con **Streamlit**, que permitirá al usuario:

1. Subir una fotografía de una hoja de café (tomada con su teléfono) o capturarla directamente desde la aplicación.
2. Procesar la imagen a través del modelo de IA previamente entrenado.
3. Recibir como resultado la clase predicha (hoja sana, enfermedad o plaga detectada).
4. La propia aplicación de **Streamlit** consulta directamente, mediante una **API key**, al modelo de lenguaje alojado en **Groq** (ver sección 4.4), el cual genera sugerencias de manejo agronómico específicas según la enfermedad o plaga detectada.
5. Consultar dichas recomendaciones directamente en la interfaz, y ser referido a un técnico del IHCAFE para confirmación y tratamiento cuando corresponda.

6.2 Plataforma de despliegue propuesta

Se propone el despliegue en **Streamlit Community Cloud**, por ser una plataforma gratuita, de fácil integración con repositorios de GitHub y adecuada para un proyecto académico de este alcance. Al no requerir un backend independiente, toda la solución (interfaz, modelo de visión y consumo de la API de recomendaciones) se despliega como un único servicio de Streamlit; la **API key de Groq** se gestionará mediante el mecanismo de *secrets* propio de la plataforma, evitando exponerla en el código fuente. Como alternativas de respaldo se considerarán:

- ❑ **Hugging Face Spaces**, para alojar el modelo y una demo interactiva.
- ❑ **Render** o **Google Cloud Platform (Cloud Run)**, en caso de requerirse mayor capacidad de cómputo o disponibilidad garantizada a futuro.
- ❑ **Google Gemini (mediante API key)**, como proveedor alternativo del módulo de

recomendaciones si en el futuro se requiere un modelo con mayor límite de tokens o capacidades adicionales de procesamiento.

7 Mantenimiento de la solución

7.1 Operación continua

Se establecerá un plan básico de monitoreo del funcionamiento de la aplicación (disponibilidad del servicio, tiempos de respuesta y errores de predicción reportados por los usuarios), utilizando los registros (*logs*) proporcionados por la plataforma de despliegue.

7.2 Estrategia de actualización del modelo

- ❑ Recolección periódica de nuevas imágenes aportadas por los propios usuarios (con su consentimiento), para ampliar y diversificar el dataset.
- ❑ Reentrenamiento del modelo cada cierto periodo (por ejemplo, semestralmente) incorporando los nuevos datos, con el fin de mejorar su exactitud y su capacidad de generalización ante distintas condiciones de campo.
- ❑ Versionado de los modelos entrenados, de manera que sea posible revertir a una versión anterior si una actualización reduce el desempeño.
- ❑ Revisión y actualización periódica del *prompt* y las reglas de negocio del **módulo de recomendaciones**, de forma independiente al modelo de visión, incorporando retroalimentación de técnicos agrónomos sobre la pertinencia de las sugerencias entregadas.

7.3 Mantenimiento preventivo y correctivo

- ❑ **Preventivo:** revisiones periódicas del código, actualización de dependencias y librerías, y pruebas de regresión antes de cada despliegue de una nueva versión del modelo.
- ❑ **Correctivo:** atención a errores reportados por los usuarios (fallos de la interfaz, predicciones claramente incorrectas) mediante un canal de retroalimentación simple integrado en la propia aplicación.

7.4 Respaldo de la información y mejoras futuras

- ❑ Respaldo periódico del código fuente en un repositorio de **GitHub**, y del dataset e imágenes recolectadas en almacenamiento en la nube.
- ❑ Como mejoras futuras se contempla: la incorporación de más enfermedades y plagas (por

ejemplo, la broca del café), el desarrollo de una aplicación móvil nativa con funcionamiento parcial sin conexión a internet, y la integración de un mapa de incidencia de enfermedades por zona geográfica, útil para IHCAFE y cooperativas locales.

8 Cronograma de actividades

El presente anteproyecto se desarrollará en un plazo comprimido de **dos semanas**, a partir de la fecha de este informe (14 de julio de 2026), de acuerdo con el siguiente cronograma:

Semana	Fechas	Actividades principales
Semana 1	14 jul	Planificación del proyecto, definición del alcance y asignación de enfermedades/plagas por integrante.
	15 – 16 jul	Búsqueda, descarga y organización de imágenes desde los repositorios públicos identificados (Mendeley Data, GitHub, Roboflow Universe, Kaggle).
	17 – 18 jul	Preprocesamiento: limpieza, etiquetado y aumento de datos (<i>data augmentation</i>) del dataset final.
	19 – 20 jul	Entrenamiento inicial del modelo CNN mediante <i>transfer learning</i> y primeras pruebas de clasificación.
Semana 2	21 – 22 jul	Evaluación del modelo (matriz de confusión, exactitud, precisión, sensibilidad) y ajuste de hiperparámetros.
	23 jul	Diseño del <i>prompt</i> y las reglas del módulo de recomendaciones, e integración de la API key de Groq en la aplicación.
	24 jul	Desarrollo de la interfaz web (Streamlit) e integración con el modelo de visión y con el módulo de recomendaciones (Groq).
	25 jul	Despliegue en Streamlit Community Cloud (incluyendo configuración segura de la API key) y pruebas piloto.
	26 – 27 jul	Ajustes finales, documentación y preparación de la entrega del anteproyecto.

9 Referencias bibliográficas

- barakobama. (s.f.). *Barakobama Coffee Leaf Disease* [Conjunto de datos]. Roboflow Universe. <https://universe.roboflow.com/barakobama/barakobama-coffee-leaf-disease>
- biniyamyoseph. (s.f.). *Ethiopian Coffee Leaf Disease* [Conjunto de datos]. Kaggle. <https://www.kaggle.com/datasets/biniyamyoseph/ethiopian-coffee-leaf-disease>
- coffee-leaf-detection. (s.f.). *ROCC* [Conjunto de datos]. Roboflow Universe. <https://universe.roboflow.com/coffee-leaf-detection/rocc>
- dame-23kub. (s.f.). *Coffee Leaf Disease* [Conjunto de datos]. Roboflow Universe. <https://universe.roboflow.com/dame-23kub/coffee-leaf-disease-kc1ca>
- izzaiqbal. (s.f.). *Capstone Project* [Conjunto de datos]. Kaggle. <https://www.kaggle.com/datasets/izzaiqbal/capstone-project>
- lance-eugene. (s.f.). *Red Spider Mite* [Conjunto de datos]. Roboflow Universe. <https://universe.roboflow.com/lance-eugene/red-spider-mite>
- letang-dataset. (s.f.). *Coffee Dataset* [Conjunto de datos]. Roboflow Universe. <https://universe.roboflow.com/letang-dataset/coffee-dataset-gh98d>
- noamaanabdulazeem. (s.f.). *JMuBEN Coffee Dataset* [Conjunto de datos]. Kaggle. <https://www.kaggle.com/datasets/noamaanabdulazeem/jmuben-coffee-dataset>
- Parraga-Alava, J., Cusme, K., Loor, A., & Santander, E. (2019). *RoCoLe: A robusta coffee leaf images dataset* [Conjunto de datos] (Versión 2). Mendeley Data. <https://data.mendeley.com/datasets/c5yvn32dzg/2>
- Sankalana, N. (s.f.). *RoCoLe – A Robusta Coffee Leaf Images Dataset* [Conjunto de datos]. Kaggle. <https://www.kaggle.com/datasets/nirmalsankalana/rocole-a-robusta-coffee-leaf-images-dataset>
- Velásquez, D., Sánchez, A., Sarmiento, S., Velásquez, C., Toro, M., Montoya, E., Maiza, M., Sierra, B., & Treftz, H. (2020). *Coffee Leaf Rust dataset* [Conjunto de datos]. GitHub. <https://github.com/dvelaren/clr-dataset/tree/master/data/0>
- yolonasv1. (s.f.). *Coffee Leaf Disease* [Conjunto de datos]. Roboflow Universe. <https://universe.roboflow.com/yolonasv1/coffee-leaf-disease>

`.roboflow.com/yolonasv1/coffee-leaf-disease-o9dbv`